

1 Exercício: Soma de duas variáveis aleatórias

Seja $X \in S \rightarrow \mathbb{R}$ um vetor aleatório. Considere que as componentes X_1 e X_2 são independentes, e que têm PDFs marginais dadas por f_{X_1}, f_{X_2} . Calcule a PDF da variável aleatória dada por $Y = X_1 + X_2$. Note que temos $Y = g(X)$ com $g : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dado por $g(x_1, x_2) = x_1 + x_2$.

Solução: Seja $h : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dado por:

$$h(x_1, x_2) = \begin{bmatrix} x_1 + x_2 \\ x_2 \end{bmatrix}$$

Seja ainda $\mathbf{w} \in \mathbb{R}^2$, podemos calcular a PDF de W no ponto \mathbf{w} , usando o teorema da PDF de uma função de vetor aleatório.

$$f_W(\mathbf{w}) = \sum_i \frac{f_X(x^{(i)})}{|\det J_h(x^{(i)})|}, \text{ com } \{x^{(1)}, x^{(2)}, \dots\}$$

o conjunto de todos os vetores $x^{(i)}$ tais que $h(x^{(i)}) = \mathbf{w}$

Calculando a matriz jacobiana:

$$\det J_h = \begin{bmatrix} \frac{\partial h_1(x_1, x_2)}{\partial x_1} & \frac{\partial h_1(x_1, x_2)}{\partial x_2} \\ \frac{\partial h_2(x_1, x_2)}{\partial x_1} & \frac{\partial h_2(x_1, x_2)}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$
$$|\det J_h(x)| = 1$$

Logo:

$$f_W(\mathbf{w}) = f_X(w_2, y - w_2)$$

Note que Y é a primeira componente de W . Logo:

$$f_Y(y) = \int_{-\infty}^{\infty} f_X(w_2, y - w_2), \text{ resposta geral para qualquer vetor } X$$

Como o vetor X é independente:

$$f_X(w_2, y - w_2) = f_{X_1}(w_2) \cdot f_{X_2}(y - w_2)$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X_1}(w_2) \cdot f_{X_2}(y - w_2) dw_2$$

Concluindo que a soma de duas VAs independentes é a convolução das PDFs originais!

2 Aplicação Prática - Vetores Gaussianos

Construímos um vetor aleatório $X \in S \rightarrow \mathbb{R}^N$ com distribuição normal. Considerando que X é não-correlato, a matriz C_{XX} será diagonal.

$$f_X(\underline{x}) = \frac{1}{\sqrt{(2\pi)^2 \cdot (\sigma_1^2 \cdot \sigma_2^2)}} \cdot \exp\left(-\frac{1}{2}(\underline{x} - \mu_{\underline{x}})^T \frac{1}{\sigma_1^2 \cdot \sigma_2^2} \begin{bmatrix} \sigma_2^2 & 0 \\ 0 & \sigma_1^2 \end{bmatrix} (\underline{x} - \mu_{\underline{x}})\right)$$
$$f_X(x_1, x_2) = \frac{1}{\sqrt{2\pi \cdot \sigma_1^2}} \cdot \frac{1}{\sqrt{2\pi \cdot \sigma_2^2}} \cdot \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \frac{1}{\sigma_1^2 \cdot \sigma_2^2} \begin{bmatrix} \sigma_2^2 & 0 \\ 0 & \sigma_1^2 \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{bmatrix}\right)$$

adiante: $f_X(x_1, x_2) = f_X(x_1) \cdot f_X(x_2)$

Algumas conclusões que podem ser obtidas:

Note que se um vetor aleatório gaussiano com 2 componentes é não-correlato então é independente. *Vimos que a PDF é separável para a Gaussiana. Isso não vale, em geral, para outras distribuições!*

Ademais, podemos notar outras propriedades como:

- Se um vetor aleatório é gaussiano, as componentes são gaussianas.
- Se um vetor aleatório $X \in S \rightarrow \mathbb{R}^N$ é gaussiano não-correlato, ele é independente.
- Se um vetor aleatório é gaussiano, a PDF é completamente determinada por pelo vetor média e matriz de covariâncias.
- A transformada de Fourier de uma PDF gaussiana é um gaussiana. No caso monovariado, variâncias maiores na PDF original em variâncias menores na transformada de Fourier.

2.1 Exemplo Computacional

Construir vetores aleatório com covariâncias não diagonal a princípio e obter as estimativas para mostrar a transformada KLT para obter uma matriz de covariâncias diagonal.

```
1 clear all; close all; clc;
2
3 % Para caso bidimensional,
4 N = 2;
5 Cxx = [1 0; 0 1];
6 mu = [0; 0];
7
8 x1 = linspace(-3*sqrt(Cxx(1,1)), 3*sqrt(Cxx(1,1)), 100);
9 x2 = linspace(-3*sqrt(Cxx(2,2)), 3*sqrt(Cxx(2,2)), 100);
10 [X1, X2] = meshgrid(x1, x2);
11 tpdf = zeros(size(X1));
12
13 for i = 1:size(X1, 1)
14     for j = 1:size(X1, 2)
15         x = [X1(i,j); X2(i,j)];
```

```

16         tpdf(i, j) = 1/sqrt((2*pi)^N * det(Cxx)) * exp(-0.5 * (x-mu).' *
17         inv(Cxx) * (x-mu));
18     end
19 end
20
21 surf(X1, X2, tpdf)
22
23 % Em dimensão superior,
24 N = 5; % dimensão
25 M = 10000; % numero de realizações
26 x = randn(N, M); % cada coluna é uma realização
27 A = [1 2 3 4 5; 2 3 4 5 6; 3 4 5 6 7; 4 5 6 7 8; 5 6 7 8 9];
28
29 % Aplicando uma transformação  $AX \sim R^N \rightarrow R^N$ 
30 for k = 1:M
31     x(1:N, k) = A * x(1:N, k);
32 end
33 [C, mu] = estimador_matriz_covariancias(x);
34
35 % Aplicando uma outra transformação  $TX \sim R^N \rightarrow R^N$ 
36 % seguindo KLT
37 y = zeros(size(x));
38
39 % Calculando autovalores e autovetores
40 [v, L] = eig(C);
41 % Sorteando autovetores e autovalores
42 [L, i] = sort(L, 'descend');
43 v = v(:, i);
44 T = v.'; % matriz de transformação KLT
45 for k = 1:M
46     y(1:N, k) = T * x(1:N, k);
47 end
48 [CYY, muY] = estimador_matriz_covariancias(y);
49
50 function [C, mu] = estimador_matriz_covariancias(matriz_dados)
51     M = size(matriz_dados, 2);
52     mu = estimador_vetor_medias(matriz_dados);
53     matriz_dados = matriz_dados - repmat(mu, 1, M);
54     C = matriz_dados * matriz_dados.';
55     C = 1 / (M - 1) * C;
56 end
57
58 function mu = estimador_vetor_medias(matriz_dados)
59     mu = sum(matriz_dados, 2)';
60     mu = mu / size(matriz_dados, 2);
61 end

```